

# Inferencia Estadística

Manuel Gijón Agudo

Octubre 2018 -

# Índice

<b>1. Tema 0: Introducción a la inferencia estadística</b>	<b>5</b>
<b>2. Tema 1: Muestreo</b>	<b>6</b>
2.1. Definiciones . . . . .	6
2.2. Métodos de muestreo . . . . .	7
2.2.1. Muestreo aleatorio simple . . . . .	7
2.3. Distribuciones de muestreo . . . . .	7
<b>3. Tema 2: Estimación de parámetros</b>	<b>8</b>
3.1. Definiciones y propiedades de los estimadores . . . . .	8
3.2. Métodos para la obtención de estimadores . . . . .	11
3.2.1. Método de los momentos . . . . .	11
3.2.2. Método de la máxima verosimilitud . . . . .	11
3.3. Métodos de remuestreo . . . . .	11
<b>4. Tema 3: Intervalos de confianza</b>	<b>12</b>
4.1. Definiciones . . . . .	12
4.2. Construcción de intervalos . . . . .	12
4.2.1. Cantidades pivotaes . . . . .	12
4.2.2. Intervalos usuales . . . . .	12
4.2.3. Intervalos de confianza asintóticos . . . . .	12
4.3. Evaluación de intervalos de confianza . . . . .	12
4.4. Determinación del tamaño muestral . . . . .	12
<b>5. Tema 4: Contraste de Hipótesis</b>	<b>13</b>
5.1. Nociones fundamentales sobre el contraste de hipótesis . . . . .	13
5.2. Test de máxima verosimilitud . . . . .	13
5.3. Test no paramétricos robustos . . . . .	13
5.4. Test múltiple . . . . .	13
5.5. Test clásicos no paramétricos . . . . .	13
5.6. Test de Fisher . . . . .	13

<i>Inferencia Estadística</i>	2
5.7. Determinación del tamaño muestral . . . . .	13
<b>6. Tema 5: Modelos de Regresión</b>	<b>14</b>
6.1. Regresión lineal simple . . . . .	14
6.1.1. Ajuste del modelo . . . . .	16
6.1.2. Tabla ANOVA . . . . .	17
6.1.3. Bondad del ajuste . . . . .	17
6.1.4. Distribución de los coeficientes . . . . .	18
6.1.5. Intervalos de confianza para los coeficientes . . . . .	20
6.1.6. Tests de significación para los coeficientes . . . . .	20
6.1.7. Predicción . . . . .	21
6.1.8. Correlación, causalidad e interpretación . . . . .	21
<b>7. Tema 6: ANOVA</b>	<b>23</b>
7.1. Único factor . . . . .	23
7.1.1. Introducción . . . . .	23
7.1.2. Estimación de los parámetros en los modelos lineales . . . . .	23
7.1.3. Factores fijos vs aleatorios . . . . .	23
7.1.4. <i>One way ANOVA fixed factor</i> . . . . .	24
7.1.5. Partición de la varianza . . . . .	25
7.1.6. Hipótesis nula . . . . .	25
7.1.7. Esperanza de la suma de cuadrados: SSR . . . . .	26
7.1.8. Esperanza de la suma de cuadrados: SSB . . . . .	26
7.1.9. Test para la hipótesis nula . . . . .	26
7.2. Suposiciones sobre el modelo . . . . .	27
7.2.1. <i>Multiple testing</i> . . . . .	28
7.2.2. ANOVA de un factor aleatorio . . . . .	28
7.3. Multifactor . . . . .	29
7.3.1. Interpretando interacciones . . . . .	29
<b>8. EJERCICIOS</b>	<b>29</b>
8.1. Tema 1 . . . . .	29

8.1.1.	Métodos de muestreo . . . . .	29
8.1.2.	Distribuciones de muestreo . . . . .	29
8.2.	Tema 2 . . . . .	30
8.2.1.	Definiciones . . . . .	30
8.2.2.	Propiedades de los estimadores . . . . .	30
8.2.3.	Métodos para la obtención de estimadores . . . . .	30
8.2.4.	Métodos de remuestreo . . . . .	36
8.3.	Tema 3 . . . . .	37
8.3.1.	Cantidades pivotaes . . . . .	37
8.3.2.	Intevalos usuales . . . . .	37
8.3.3.	Intervalos de confianza asintóticos . . . . .	37
8.3.4.	Evaluación de intervalos de confianza . . . . .	37
8.3.5.	Determinación del tamaño muestral . . . . .	37
8.4.	Tema 4 . . . . .	38
8.4.1.	Test de máxima verosimilitud . . . . .	38
8.4.2.	Test no paramétricos robustos . . . . .	41
8.4.3.	Test múltiple . . . . .	41
8.4.4.	Test clásicos no paramétricos . . . . .	41
8.4.5.	Test de Fisher . . . . .	41
8.4.6.	Determinación del tamaño muestral . . . . .	41
8.5.	Tema 5 . . . . .	42
8.5.1.	Ajuste del modelo . . . . .	42
8.5.2.	Table ANOVA . . . . .	42
8.5.3.	Bondad del ajuste . . . . .	42
8.5.4.	Distribución de los coeficientes . . . . .	42
8.5.5.	Intervalos de confianza para los coeficientes . . . . .	42
8.5.6.	Predicción . . . . .	42
8.5.7.	Correlación, causalidad e interpretación . . . . .	42
8.6.	Tema 6 . . . . .	43
8.6.1.	Estimación de parámetros (un factor) . . . . .	43

---

8.6.2. Partición de la varianza (un factor) . . . . .	43
8.6.3. Hipótesis nula y tests para la hipótesis nula . . . . .	43

## 1. Tema 0: Introducción a la inferencia estadística

## 2. Tema 1: Muestreo

### 2.1. Definiciones

#### Definiciones:

- Denominamos **población** al conjunto que presenta la característica que estamos interesados en estudiar.
- **Muestra** es un subconjunto de la población. La intención al tomarlo es que sea **representativo**, esto es que cada individuo sea elegido de manera aleatorio, todo tienen las mismas probabilidades de serlo. Cada subconjunto de  $k$  individuos debe tener las mismas probabilidades de ser elegido que cualquier otro conjunto de  $k$  individuos. A esta técnica y proceso se le denomina **Muestreo aleatorio**.
- **Muestreo**: proceso por el que tomamos una muestra.

Algunas razones para realizar muestreo podían ser las siguientes:

- Económicas.
- Temporales.
- De destrucción de la muestra tras su análisis.

Entre los métodos de muestreo se encuentran los siguientes:

- **Muestreo aleatorio simple:**
- **Muestreo sistemático:**
- **Muestreo estratificado:**
- **Muestreo de clústering:**
- 'Quota sampling'
- 'Panel sampling'

**Definición:** Decimos que una muestra es **aleatoria simple** cuando cumple lo siguiente:

- Cada elemento de la población y todos los posibles subconjuntos de la población tienen la misma probabilidad de ser elegidos. Esto nos asegura la **representatividad**.
- Seleccionar un elemento no condiciona el seleccionar otro. En esto consiste la **independencia**.

Una muestra aleatoria simple  $X_1, X_2, \dots, X_n$  es una colección de  $n$  variables aleatorias tales que:

- Son independientes.
- Siguen la misma distribución de probabilidad.

**Obs:** las variables aleatorias que conforman una muestra aleatoria simple son idénticas e igualmente distribuidas (iid).

**Definición:** el conjunto de  $n$  observaciones  $(x_1, \dots, x_n)$  provenientes de  $(X_1, \dots, X_n)$  se denomina **realización muestral**.

**Definición:** la **distribución conjunta** de una muestra aleatoria viene dada por la siguiente función de densidad:

$$l(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i|\theta)$$

que se denomina **función de densidad conjunta (likelihood function)**. Usaremos este término tanto en el caso discreto como en el continuo.

Ejemplo:  $X \sim N(\mu, \sigma)$

$$f_X(x|\mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$$

Conocemos la distribución de  $X$  pero no los parámetros  $\theta = (\mu, \sigma)$ . La función de distribución para  $n$  variables aleatorias iid será:

$$\begin{aligned} l(\mu, \sigma; x_1, \dots, x_n) &= \prod_{i=1}^n f(x_i|\mu, \sigma) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2} \end{aligned}$$

**Definición:** denominamos a una función  $T$  que solamente depende de los valores de una muestra aleatoria  $X_1, \dots, X_n$  un **estadístico**. Destacar que solamente depende de los valores observados pero no de los parámetros que determinan la variable aleatoria que los ha generado. Por supuesto un estadístico es también una variable aleatoria.

**Definición:** Los estadísticos que utilizamos para estimar el valor de la variable  $\theta$  son denominados **estimadores**.

**Definición:** La distribución que sigue  $Y = T(X_1, \dots, T_n)$  es denominada **distribución muestral**.

## 2.2. Métodos de muestreo

### 2.2.1. Muestreo aleatorio simple

### 2.3. Distribuciones de muestreo



### 3. Tema 2: Estimación de parámetros

#### 3.1. Definiciones y propiedades de los estimadores

##### Definiciones:

- Sean  $X_1, \dots, X_n$  una secuencia de variables aleatorias independientes idénticamente distribuidas tales que  $X \sim f(x; \theta)$   $\theta \in \Theta$ .
- Definimos la **estimación puntual** el parámetro  $\theta$  como el proceso de seleccionar un estadístico<sup>1</sup>  $T$  que mejor estima el valor del parámetro para esa población.
- Llamaremos a este estadístico  $T = T(X_1, \dots, X_n)$  que utilizamos para estimar  $\theta$  un **estimador**.

##### Observaciones:

- Los estimadores son variables aleatorias.
- Usaremos sus propiedades estadísticas para estudiar su calidad y comparar entre ellos varios estimadores.
- Siempre tendremos un error en la estimación, nuestro objetivo será minimizarlo.

**Definición:** Decimos que un estimador  $T_n = T(X_1, \dots, X_n)$  para el parámetro  $\theta$  es **consistente** cuando  $\forall \epsilon > 0$ :

$$\lim_{n \rightarrow \infty} P(|T_n - \theta| \geq \epsilon) = 0$$

Ejemplo de la media aritmética como estimador, usando chebychev's

**Teorema:** si  $T_n$  es una secuencia de estimadores tales que  $E(T_n) \longleftrightarrow \theta$  y  $V(T_n) \longleftrightarrow 0$  cuando  $n \rightarrow \infty$  entonces  $T_n$  es consistente para el parámetro  $\theta$ .

##### Definiciones:

- Definimos la **desviación** de un estimador  $T$  como:

$$bias(T) = E(T) - \theta$$

- Sea  $T$  un estimador para  $\theta$ . Decimos que el estimador es **no desviado** si  $\forall \theta \in \Theta$ :

$$E(T) = \theta$$

En caso contrario decimos que es **desviado**. Es obvio que en este caso  $bias(T) \neq 0$ .

Para introducir el siguiente concepto usaremos un ejemplo concreto. Sean  $X_1, \dots, X_n$  una muestra aleatoria de una variable tal que  $E(X) = \mu$  y  $V(X) = \sigma^2$ . Probar que:

$$E(\bar{X}_n) = \mu$$

---

<sup>1</sup>**Estadístico:** es una función medible que tiene como espacio de salida  $(X_1, \dots, X_n)$  una muestra estadística de valores.

$$E(S^2) = \frac{n-1}{n} \sigma^2$$

ENCONTRAR ESTA MIERDA Y CONTINUAR A PARTIR DE AQUÍ, MUHAHH-HAHHHAHHHAHHHA

**Corrección de la desviación:**

$$\widehat{S^2} = \frac{n}{n-1} S^2 \Rightarrow E(\widehat{S^2}) = \sigma^2$$

**Definición:** Sea  $T_n$  un estimador, decimos que es un estimador de  $\theta$  asintóticamente no desviado si, para  $n \rightarrow \infty$ :

$$E(T_n) \rightarrow \theta$$

Sea  $X \sim Unif(0, \theta)$  y sea el estimador para  $\theta$   $T = \max X_1, \dots, X_n = X_{(n)}$ . Verificar que es no desviado, ¿es consistente?

Es fácil comprobar los siguiente:

$$\begin{aligned} F_{X_{(n)}} &= P(X_{(n)} \leq x) = P(X_1 \leq x, \dots, X_n \leq x) \\ &= \prod_{i=1}^n P(X_i \leq x) = \frac{x^n}{\theta^n} \end{aligned}$$

Para  $0 < x < \theta$ :

$$f_{X_{(n)}} = n \frac{x^{n-1}}{\theta^n}$$

$$E(X_{(n)}) = \int_0^\theta x n \frac{x^{n-1}}{\theta^n} dx = \theta \frac{n}{n+1} < \theta$$

$$\begin{aligned} E(X_{(n)}^2) &= \int_0^\theta x^2 n \frac{x^{n-1}}{\theta^n} dx = \theta^2 \frac{n}{n+2} \\ &\Rightarrow Var(X_{(n)}) = \frac{\theta^2 n}{(n+1)^2 (n+2)} \end{aligned}$$

DESDE AQUÍ CONTINUAMOS EXPLICÁNDO EL RESULTADO DETALLADAMENTE

**Observaciones:**

- En general, si el momento poblacional  $k$ -ésimo  $m_k$  existe, entonces el momento muestral  $k$ -ésimo es no desviado para  $m_k$ .

- Si  $T$  es no desviado para  $\theta$ ,  $g(T)$  no lo es, en general, el estimador  $g(\theta)$  REPASARLO POR QUE NO ENTIENDO QUE DICE
- Los estimadores no desviados no siempre existen.
- En ocasiones el uso de estimadores no desviados puede ser absurdo.

**Definición:** Decimos que el estimador  $T_1$  es más **eficiente** que el estimador  $T_2$  (ambos no desviados) si:

$$Var(T_1) < Var(T_2)$$

**Definición:** Definimos la **eficiencia** del estimador  $T_1$  relativa al estimador  $T_2$  (ambos no desviados) como:

$$eff(T_1|T_2) = \frac{Var(T_2)}{Var(T_1)}$$

Observemos que  $T_1$  es más eficiente que  $T_2$  si  $eff(T_1|T_2) < 1$ .

**Definición:** Decimos que  $T$  es el estimador de mínima varianza no desviado para  $\theta$  si  $E(T) = \theta$  y para cualquier otro estimador  $T'$  tal que  $E(T') = \theta$  ocurre:

$$Var(T) \leq Var(T')$$

Podemos encontrar una cota inferior para la varianza de un estimador no desviado:

**Teorema, Cota de Cramer-Rao (CRB):** bajo ciertas condiciones de regularidad y siendo  $X_1, \dots, X_n$  variables aleatorias idénticamente distribuidas que siguen la función de densidad  $f(x; \theta)$ , si  $T_n$  es un estimador no desviado para  $\theta$ , entonces:

$$Var(T_n) \geq \frac{1}{nE\left(\left(\frac{d}{d\theta} \ln f(x; \theta)\right)^2\right)}$$

**Obs:** Podemos definir la eficiencia absoluta de un estimador no desviado  $T_n$  como:

$$eff(T_n) = \frac{CRB}{Var(T_n)}$$

**Definición:** Denominamos a la siguiente cantidad **información de Fisher**,  $\mathcal{I}_X(\theta)$ :

$$E\left(\left(\frac{d}{d\theta} \ln f(x; \theta)\right)^2\right) = -E\left(\frac{d^2}{d\theta^2} \ln f(x; \theta)\right)$$

Esta es una medida de la cantidad de información que la variable  $X$  contiene del parámetro  $\theta$ . Cuanto mayor sea la cantidad de Fisher menor será la varianza y en consecuencia, la estimación será más precisa.

Si  $\mathcal{X} = (X_1, \dots, X_n)$  es una muestra aleatoria entonces  $\mathcal{I}_{\mathcal{X}}(\theta) = n\mathcal{I}_X(\theta)$  es la información de Fisher que la muestra aporta sobre el parámetro.

Una forma más general de límite puede ser obtenida considerando un estimador no desviado  $T(\mathcal{X})$  de una función  $\psi(\theta)$  del parámetro  $\theta$ .

$$\text{Var}(T_n) \geq \frac{(\psi'(\theta))^2}{n\mathcal{I}_{\mathcal{X}}(\theta)}$$

### 3.2. Métodos para la obtención de estimadores

#### 3.2.1. Método de los momentos

#### 3.2.2. Método de la máxima verosimilitud

### 3.3. Métodos de remuestreo

---

## 4. Tema 3: Intervalos de confianza

### 4.1. Definiciones

### 4.2. Construcción de intervalos

#### 4.2.1. Cantidades pivotaes

#### 4.2.2. Intervalos usuales

#### 4.2.3. Intervalos de confianza asintóticos

### 4.3. Evaluación de intervalos de confianza

### 4.4. Determinación del tamaño muestral

---

## 5. Tema 4: Contraste de Hipótesis

- 5.1. Nociones fundamentales sobre el contraste de hipótesis
  - 5.2. Test de máxima verosimilitud
  - 5.3. Test no paramétricos robustos
  - 5.4. Test múltiple
  - 5.5. Test clásicos no paramétricos
  - 5.6. Test de Fisher
  - 5.7. Determinación del tamaño muestral
-

## 6. Tema 5: Modelos de Regresión

### 6.1. Regresión lineal simple

El objetivo es modelar la relación entre una variable respuesta  $Y$  y una variable aleatoria explicativa  $X_1$ . Más tarde lo generalizaremos a conjuntos de variables explicativas  $X_1, \dots, X_{p-1}$ .

En la práctica, además de la variable explicativa  $X_1$  tendremos también otras variables explicativas  $Z_1, \dots, Z_r$  que nos serán desconocidas. El hecho de no tener en cuenta esas variables tendrá repercusiones sobre la bondad del modelo.

Nuestros modelos podrán ser tanto deterministas como aleatorios.

- En un **modelo determinista** la variable respuesta  $Y$  se relaciona con las variables explicativas mediante una función matemática que involucra constantes  $\beta$ ,  $f(X_1, X_2, \dots, X_{p-1}|\beta)$ .

De acuerdo con estos modelos, fijados los valores de las variables explicativas podemos obtener el valor de la variable respuesta exactamente.

- Movimiento parabólico

$$f(t|v_0, G, \alpha) = v_0 + \text{sen } t(\alpha) - \frac{1}{2} \cdot G \cdot t^2$$

- Ley de Ohm

$$f(I|R) = I \cdot R = Y$$

- En los **modelos estadísticos** el valor de la variable respuesta es una combinación de los valores obtenidos mediante las variables explicativas más otro término de **ruido**.

$$Y = \text{Señal} + \text{ruido}$$

**Observación:** a partir de este punto asumiremos durante todo el capítulo que solo contamos con una única variable explicativa  $X_1 = X$  y que nuestro modelo es el siguiente:

$$Y_i = \beta_0 + \beta_1 \cdot X_i + \epsilon$$

donde  $\beta_0, \beta_1 \in \mathbb{R}$  son desconocidos, son los parámetros a ajustar y los subíndices  $i$  hacen referencia a la observación  $i$ -ésima. Al tener una única variable el modelo se corresponde con una recta, al tener más lo hará con planos de diferentes dimensiones.

**Suposiciones sobre los  $\epsilon$ :**

- $H_1 : E(\epsilon_i) = 0, \quad i = 1, 2, \dots, n$
- $H_2 : V(\epsilon_i) = \sigma^2, \quad i = 1, 2, \dots, n$
- $H_3 : \epsilon_i \sim N(0, \sigma)$
- $H_4 : \epsilon_i$  es independiente de  $\epsilon_j \quad \forall i \neq j \Rightarrow \text{cov}(\epsilon_i, \epsilon_j) = \text{corr}(\epsilon_i, \epsilon_j) = 0$

Notar que  $\sigma^2$  es un tercer parámetro desconocido del modelo.

Estas suposiciones son equivalentes a las siguientes:

- $H_1 : E(y_i|x_i) = \beta_0 + \beta_1 x_1$  (**Linealidad**)
- $H_2 : V(y_i|x_i) = \sigma^2$  (**Varianza constante**)
- $H_3 : y_i|x_i \approx \text{Normal}$  (**Normalidad**)
- $H_4 : y_i|x_i$  independiente de  $y_j|x_j$  (**Independencia**)

- $E(\epsilon_i) = 0 \Rightarrow E(y_i|x_i) = \beta_0 + \beta_1 x_1$  (**Linealidad**)<sup>2</sup>

$$\begin{aligned} E(Y_i) &= E(\beta_0 + \beta_1 x_i + \epsilon_i) \\ &= E(\beta_0 + \beta_1 x_i) + E(\epsilon_i) \\ &= \beta_0 + \beta_1 x_i + 0 = \beta_0 + \beta_1 x_i \end{aligned}$$

- $V(\epsilon_i) = \sigma^2 \Rightarrow V(y_i|x_i) = \sigma^2$  (**Varianza constante**)<sup>3</sup>

$$\begin{aligned} V(Y_i) &= V(\beta_0 + \beta_1 x_i + \epsilon_i) \\ &= V(\beta_0 + \beta_1 x_i) + V(\epsilon_i) \\ &= 0 + V(\epsilon_i) = 0 + 0 = 0 \end{aligned}$$

- $\epsilon_i \sim N(0, \sigma) \Rightarrow y_i|x_i \approx \text{Normal}$  (**Normalidad**)  
DEMOSTRAR ESTA MERDA
- $\epsilon_i$  es independiente de  $\epsilon_j \quad \forall i \neq j \Rightarrow y_i|x_i$  independiente de  $y_j|x_j$  (**Independencia**)  
DEMOSTRAR ESTA MIERDA

Como veremos más adelante las dos primeras (linealidad y varianza constante) son las suposiciones con más importancia.

De nuevo otra equivalencia, esto es equivalente:

$$Y_i|X_i \sim N(\beta_0 + \beta_1 X_i, \sigma) \text{ independientes}$$

No es necesaria una normalidad global, pero sí una normalidad en los valores de  $y_i$  que comparten el mismo  $x_i$ . La consecuencia es que  $Y$  debe ser continuo (o casi continuo).

---

<sup>2</sup>Propiedades de la **esperanza**:

- $E(X + c) = E(X) + c$
- $E(X + Y) = E(X) + E(Y)$
- $E(aX) = aE(X)$
- $E(X \cdot Y) = E(X) \cdot E(Y)$  si son independientes.

<sup>3</sup>Propiedades de la **varianza**:

- $V(X) \geq 0$
- $V(aX + b) = a^2 V(X)$
- $V(X + Y) = V(X) + V(Y) + 2 \cdot \text{Cov}(X, Y)$
- $V(X - Y) = V(X) + V(Y) - 2 \cdot \text{Cov}(X, Y)$
- $V(Y) = E(V(Y|X)) + V(E(Y|X))$  (Varianza por Pitágoras).



### 6.1.1. Ajuste del modelo

Una vez tenemos las parejas de datos  $(x, y)$  queremos ajustar el modelo:

$$Y_i = b_0 + b_1 \cdot X_1$$

**Observación:**  $\beta_0$  y  $\beta_1$  son valores desconocidos pero fijos.

Resumiendo, tendremos:

- Nuestro modelo teórico:

$$Y_i = \beta_0 + \beta_1 \cdot X_1 + \epsilon_i$$

- El modelo ajustado con el que trabajaremos:

$$Y_i = b_0 + b_1 \cdot X_1 + e_i$$

- A la diferencia la llamaremos **residuo**:

$$e_i = Y_i - (b_0 + b_1 \cdot X_1)$$

**Criterio de los mínimos cuadrados:** el criterio que utilizaremos para hallar los valores. Nuestro siguiente problema consistirá en minimizar las siguientes expresiones:

- Minimizar:  $\sum_{i=1}^n |e_i|$
- Minimizar:  $Q(b_0, b_1) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - b_0 - b_1 \cdot X_1)^2$

Haciendo los cálculos llegamos a la conclusión de que los estimadores de mínimos cuadrados para  $b_0$  y  $b_1$  son:

$$\begin{aligned} \frac{\partial Q}{\partial b_0} &= -2 \cdot \sum_{i=1}^n (Y_i - b_0 - b_1 \cdot X_1) = 0 \\ \frac{\partial Q}{\partial b_1} &= -2 \cdot \sum_{i=1}^n (Y_i - b_0 - b_1 \cdot X_1) \cdot X_1 = 0 \end{aligned}$$

A este conjunto de ecuaciones  $Q(b_0, b_1) = SQ_R(b_0, b_1)$  se les denomina **ecuaciones normales** (*normal equations*).

Podemos reescribir ambas ecuaciones respectivamente como:

(PROBARLO QUEDA PENDIENTE)

$$\begin{aligned} \frac{\partial Q}{\partial b_0} &= \sum_{i=1}^n e_i = 0 \\ \frac{\partial Q}{\partial b_1} &= \sum_{i=1}^n e_i \cdot X_1 = 0 \end{aligned}$$

Las soluciones de las ecuaciones normales son las siguientes:

(PROBARLO QUEDA PENDIENTE)

$$b_0 = \frac{\sum_{i=1}^n (X_i - \bar{X}) \cdot (Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sum_{i=1}^n (X_i - \bar{X}) \cdot Y_i}{\sum_{i=1}^n (X_i - \bar{X})^2} = \sum_{i=1}^n C_i \cdot Y_i$$

$$b_1 = \bar{Y} - b_0 \cdot \bar{X} = \frac{\sum_{i=1}^n Y_i - b_0 \cdot \sum_{i=1}^n X_i}{n} = \sum_{i=1}^n C'_i \cdot Y_i$$

Usando este criterio siempre tendremos (en otros casos no es seguro):

- $b_0$  y  $b_1$  son combinaciones lineales de  $y_i$ .
- La media muestral de los residuos es 0.
- La recta ajustada siempre pasa por el punto  $(\bar{X}, \bar{Y})$  y es la siguiente:

$$\hat{Y}_i = \bar{Y} + b_1 \cdot (X_i - \bar{X})$$

### 6.1.2. Tabla ANOVA

Es claro que  $Y_i - \bar{Y} = Y_i - \bar{Y} + \hat{Y}_i - \hat{Y}_i$ , observemos que  $Y_i - \hat{Y}_i$  son los residuos.

$$\sum_{i=1}^n (Y_i - \bar{Y}) = \sum_{i=1}^n (Y_i - \hat{Y}_i) + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})$$

También es posible demostrar lo siguiente:

HACER LOS CÁLCULOS DETALLADAMENTE...

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

O lo que es lo mismo:

Variabilidad total del proceso = variabilidad residual (no explicada por el modelo) + variabilidad explicada por el modelo

AQUÑI IRÁ UNA TABLA MUHAHAHAHAHA

La **Suma total de cuadrados**  $SQ_T$  solamente depende de  $y$  y en absoluto de  $x$ . Notemos también que:  $SQ_T = (n-1)s_y^2$

Sin embargo, tanto  $SQ_E$  y  $SQ_R$  dependen de  $x_i$  y por tanto del modelo.

Sin no realizamos ninguna transformación en  $Y$ , cuanto mayor sea  $SQ_E$  y menor  $SQ_R$  **mejor será el modelo**.

### 6.1.3. Bondad del ajuste

Definimos el **coeficiente de determinación**  $R$  como:

$$R = \frac{\text{Suma de cuadrados explicados por la regresión}}{\text{Total de cuadrados}}$$

$$R = \frac{SQ_E}{SQ_T} = \frac{SQ_T - SQ_R}{SQ_T} = 1 - \frac{SQ_R}{SQ_T} = 1 - \frac{S_R^2 \cdot (n-2)}{S_Y^2 \cdot (n-1)}$$

$$0 \leq R^2 \leq 1$$

Normalmente el coeficiente de determinación se expresa en forma de porcentaje.

$R^2$  es el porcentaje de variabilidad de la respuesta explicado por el modelo.

**Observación:** Solamente en el caso del modelo lineal simple el valor de  $R^2$  se corresponde con el cuadrado de la correlación muestral entre  $X$  e  $Y$ .<sup>4</sup>

La covarianza y el coeficiente de correlación muestral miden el grado de **dependencia lineal** entre dos variables. Definimos la **covarianza** como:

$$C_{xy} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{n-1}$$

El **coeficiente de correlación muestral**, que es adimensional, se expresa de la siguiente manera:

$$r_{xy} = \frac{C_{xy}}{S_x \cdot S_y} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}} = \frac{\sum_{i=1}^n (X_i - \bar{X}) \cdot Y_i}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

Propiedad:  $-1 \leq r_{xy} \leq 1$

**Observación:** En el caso de la regresión lineal múltiple  $R^2$  es el cuadrado del coeficiente de correlación entre  $Y$  y la mejor combinación lineal de todas las variables explicativas que se corresponde con el valor predicho.

Es también simple comprobar:

$$b_1 = \frac{c_{xy}}{S_x^2} = r_{xy} \cdot \left( \frac{S_y}{S_x} \right)$$

HACER, EJERCICIO

#### 6.1.4. Distribución de los coeficientes

Hasta ahora no hemos utilizando las hipótesis del modelo, varianza constante, normalidad e independencia. Estas nos serán necesarias a la hora de encontrar las distribuciones de los valores ajustados  $b_0$  y  $b_1$ .

---

<sup>4</sup> $R^2 = (r_{xy})^2$

Necesitaremos conocer estas distribuciones para poder hacer inferencia sobre  $\beta_0$  y  $\beta_1$ . Construir intervalos de confianza y test de significación para  $\beta_0$  y  $\beta_1$  y también hacer predicciones sobre los futuros valores de  $y$ .

Para un conjunto de  $X_i$ , hemos simulado gran cantidad de muestras  $(X_i, Y_i)$  basándonos en el modelo teórico  $Y_i = \beta_0 + \beta_1 \cdot X_i + \epsilon_i$  donde los parámetros  $\beta_0$ ,  $\beta_1$  y  $\sigma^2$  son conocidos para el simulador.

Para cada conjunto, calculamos utilizando mínimos cuadrados los valores  $b_0, b_1$  y  $S_R^2$ .

Para encontrar las distribuciones teóricas de  $b_0, b_1$  y  $S_R^2$  necesitaremos las cuatro hipótesis en las que basamos el modelo teórico:

$$Y_i|X_i \sim N(\beta_0 + \beta_1 \cdot X_i, \sigma) \text{ independientes}$$

$b_0$  y  $b_1$  son combinaciones lineales de las  $y_i$ 's y si estas siguen una distribución normal entonces si el modelo es correcto las  $b_0$  y  $b_1$  también seguirán una distribución normal.

Si el modelo es correcto entonces:

- $E(b_0) = \beta_0$
- $V(b_0) = \frac{\sigma^2}{n} \cdot \frac{\sum_{i=1}^n X_i^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$

y también:

- $E(b_1) = \beta_1$
- $V(b_1) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$

Siendo la covarianza entre ambos:

$$\text{cov}(b_0, b_1) = \frac{-\bar{X} \cdot \sigma}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Entonces nos queda:

$$b_0 \sim N\left(\beta_0; \sqrt{\frac{\sigma^2}{n} \cdot \frac{\sum_{i=1}^n X_i^2}{\sum_{i=1}^n (X_i - \bar{X})^2}}\right)$$

$$b_1 \sim N\left(\beta_1; \sqrt{\frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}}\right)$$

Cuanto menor sea  $V(b_1)$  más cercano estará  $b_1$  al verdadero valor de  $\beta_0$ .

¿Cómo minimizaríamos  $V(b_1)$ ? RESPONDER ¿por qué la covarianza entre  $b_0$  y  $b_1$  no es cero? RESPONDER

$V(b_0)$  y  $V(b_1)$  dependen de  $\sigma^2$ , desconocido. Para estimar estas cantidades remplazaremos  $\sigma^2$  por su estimador  $S_R^2$ .

$$S_{b_0}^2 = \frac{S_R^2}{n} \cdot \frac{\sum_{i=1}^n X_i^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$S_{b_1}^2 = \frac{S_R^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

En la tabla ANOVA podemos encontrar la varianza residual:

$$S_R^2 = \frac{\sum_{i=1}^n e_i^2}{n - 2}$$

El estimador está dividido por  $n - 2$  en lugar de por  $n - 1$  o  $n$  para que sea **insesgado**:

$$E(S_R^2) = \sigma^2$$

PROBAR ESTA COSA AÑADIENDO AQUÍ LOS CÁLCULOS OPORTUNOS

#### 6.1.5. Intervalos de confianza para los coeficientes

Usando las propiedades de la distribución normal podemos crear intervalos de confianza para  $\beta$ :

$$[b_i - t_{\frac{\alpha}{2}, n-2} \cdot S_{b_i}; b_i + t_{\frac{\alpha}{2}, n-2} \cdot S_{b_i}]$$

con un nivel de confianza  $(1 - \alpha)$ .<sup>5</sup>

¿Podría ser  $\beta_1 = 1$  en el modelo teórico?

RESOLVER

¿Por qué  $cov(b_0, b_1) \neq 0$ ?

RESOLVER

#### 6.1.6. Tests de significación para los coeficientes

$$H_0 : \beta_1 = 0$$

$$H_1 : \beta_1 \neq 0$$

(de igual manera para  $\beta_0$ ).

Si  $H_0$  es cierta, entonces  $t_1 = \frac{b_1}{S_{b_1}} \sim t\text{-Student}$ , con  $\nu = n - 2$ .

INSERTAR IMÁGEN DE T CON DOS COLAS!!

- Si  $|t_1| > 2$  y el modelo es correcto, entonces rechazamos  $H_0$  y **no** podemos **eliminar** la variable  $x_1$  del modelo.

---

<sup>5</sup>El intervalo de confianza contendrá el verdadero valor de  $\beta_i$  un  $(1 - \alpha)$  por ciento de las veces.

- Si  $|t_1| < 2$  y el modelo es correcto, entonces no podemos rechazar  $H_0$  y podemos **eliminar** la variable  $x_1$  del modelo.

Con lo anterior podemos discriminar si las variables nos sirven o no para predecir el valor de  $Y$ . Usaremos este procedimiento para simplificar el modelo.

Para averiguar si  $\beta_1$  pudiera ser igual a 0 o no, necesitamos saber si  $|t_1| = \left| \frac{b_1}{S_{b_1}} \right|$  es grande o pequeño.

$$H_0 : \beta_1 = a$$

$$H_1 : \beta_1 \neq a$$

Si  $H_0$  es cierta, entonces  $t = \frac{b_1 - a}{S_{b_1}} \sim t\text{-Student}$ , con  $\gamma = n - 2$ .

INSERTAR IMÁGEN DE T CON DOS COLAS!!

- Si  $|t| > 2$  (el **p-valor** es más pequeño que 0,05) y el modelo es correcto entonces **rechazamos**  $H_0$ .
- Si  $|t| < 2$  (el **p-valor** es mayor que 0,05) y el modelo es correcto entonces **no podemos rechazar**  $H_0$ .

#### 6.1.7. Predicción

El **intervalo de confianza** al  $(1 - \alpha)$  para predecir el valor de  $Y$  en  $X_0$ ,  $E(Y|X_0)$ , es:

$$\left[ (b_0 + b_1 \cdot X_0) - t_{\frac{\alpha}{2}, n-2} \cdot \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2}}; (b_0 + b_1 \cdot X_0) + t_{\frac{\alpha}{2}, n-2} \cdot \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2}} \right]$$

EXPLICAR EL POR QUÉ ES ASÍ CON DETALLE

Si el valor de  $X_0$  se encuentra dentro del rango de valores de  $X$  que hemos usado para ajustar el modelo, nos encontramos frente a una **interpolación**.

De otra manera, la predicción es una **extrapolación** y puede ser justificada **si y solo si** asumimos que el modelo teórico es válido no solo en el rango de las variables con las que lo hemos ajustado si no más allá. **Debemos tener cuidado al asumir esto.**

#### 6.1.8. Correlación, causalidad e interpretación

Analysing a bivariate diagram or adjusting a linear model between two variables means that they are related but doesn't mean that X is cause of Y .

You can have another predictor hidden which is the one who does changes in both X and Y .

¿Cómo podríamos saber si la relación entre dos variables es causal o no?

RESPONDER

---

## 7. Tema 6: ANOVA

### 7.1. Único factor

#### 7.1.1. Introducción

Poniendo las cosas en contexto:

- **Modelo estadísticos**

$$\text{variable respuesta} = \text{modelo} + \text{error}$$

- **Modelos lineales**

$$y_i = \underbrace{\beta_0}_{\text{intercepto}} + \underbrace{\beta_1}_{\text{pendiente}} \cdot \underbrace{x_1}_{\text{variable predictora}} + \beta_2 \cdot x_2 + \cdots + \epsilon_i$$

modelo

- **Modelos para la variables categóricas predictivas: modelo para los efectos (*effects model*)**

$$y_{ij} = \mu + \alpha_i + \epsilon_{ij}$$

$$y_{ijk} = \mu + \alpha_i + \beta_j + \epsilon_{ijk}$$

donde  $k$  representa el conjunto de réplicas.

#### 7.1.2. Estimación de los parámetros en los modelos lineales

- Los parámetros pueden ser estimados utilizando cualquiera de los métodos de estimación, entre los más usuales se encuentran **Mínimos cuadrados** (*Ordinary least squares, OLS*) y **Máxima verosimilitud** (*maximum likelihood, ML* o también *REML*).
- Los modelos que asumen una distribución normal para los errores, y que frecuentemente utilizan OLS, son denominados de forma genérica **modelos lineales generalizados** (*'general' linear models*). Nos encontramos con varios tipos:
  - **Modelos de Regresión** (*Regression models*): variables predictivas continuas.
  - **ANOVA** (*Analysis of variance*) variables predictivas categóricas.
  - **ANCOVA** (*Analysis of covariance*): incorporan tanto variables predictivas categóricas como continuas.
- El estimador por máxima verosimilitud se utiliza en ocasiones también para los modelos lineales generalizados, luego no se restringe a modelos donde tanto los residuos como la respuesta siguen una distribución normal.

#### 7.1.3. Factores fijos vs aleatorios

**Factores fijos** (*Fixed factors*): son factores cuyos niveles representan la población de interés completa.

**Factores aleatorios** (*Random factors*): son factores cuyos niveles han sido aleatoriamente elegidos de entre todos los posibles niveles de interés, representan muestras aleatorias de los mismos.



### 7.1.4. One way ANOVA fixed factor

Notación:

$$y_{ij} = \mu + \alpha_i + \epsilon_{ij} \quad i = 1, \dots, a \quad j = 1, \dots, n_i$$

- $\mu$ : overall mean.
- $\alpha_i$ : efecto del grupo  $i$ , factor fijo.
- $\epsilon_{ij}$ : error aleatorio.

Terminología:

- **Replicación** (*Replicate*): observaciones hechas bajo las mismas condiciones experimentales.
- **Diseño balanceado** (*Balance design*): diseño experimental donde todas las células tienen el mismo número de réplicas.
- **Factor**: una fuente de variación controlada.
- **Nivel** (*Level*): cada uno de los diferentes valores de un factor.

El modelo **ANOVA de un factor fijo** nos queda:

$$y_{ij} = \mu + \alpha_i + \epsilon_{ij} \quad i = 1, \dots, a \quad j = 1, \dots, n_i$$

Donde debemos asumir:

$$\epsilon_{ij} \text{ iid } \epsilon_{ij} \sim N(0, \sigma^2)$$

Los **residuos** son:

- Independientes los unos de los otros.
- Normalmente distribuidos.
- Tienen la propiedad de la **homeostacididad** (tienen la misma varianza).

Además el modelo cumple:

$$E(\bar{Y}) = \frac{N\mu + \sum_{i=0}^a n_i \alpha_j}{N} = \mu \Rightarrow \sum_{i=0}^a n_i \alpha_j = 0$$

donde  $N = \sum_{i=0}^a n_i$ .

$$y_{ij} = \mu + \alpha_i + \epsilon_{ij} = \mu + \underbrace{(\mu_i - \mu)}_{\alpha_i} + \underbrace{(y_{ij} - \mu_i)}_{\epsilon_{ij}} \Rightarrow$$

$$\underbrace{y_{ij} - \mu}_{\text{Total}} = \underbrace{(\mu_i - \mu)}_{\text{Efecto de los factores}} + \underbrace{(y_{ij} - \mu_i)}_{\text{Interacciones}}$$

Estimación OLS:

$$\epsilon_{ij} = y_{ij} - \mu - \alpha_i$$

$$\|\epsilon_{ij}\|^2 = \|y_{ij} - \mu - \alpha_i\|^2 = \sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \mu - \alpha_i)^2$$

$$\frac{\partial \|\epsilon_{ij}\|^2}{\partial \mu} = -2N(\bar{Y} - \mu) = 0 \Rightarrow \hat{\mu} = \bar{Y}$$

$$\frac{\partial \|\epsilon_{ij}\|^2}{\partial \alpha_i} = -2n_i(\bar{Y}_{i\cdot} - \bar{Y} - \alpha_i) = 0 \Rightarrow \hat{\alpha}_i = \bar{Y}_{i\cdot} - \bar{Y} \Rightarrow \hat{\mu}_i = \bar{Y}_{i\cdot}$$

#### 7.1.5. Partición de la varianza

$$y_{ij} - \mu = (\mu_i - \mu) + (y_{ij} - \mu_i)$$

$$y_{ij} - \bar{Y} = (\bar{Y}_{i\cdot} - \bar{Y}) + (y_{ij} - \bar{Y}_{i\cdot})$$

$$\begin{aligned} \overbrace{\sum_i \sum_j (y_{ij} - \bar{Y})^2}^{\text{SST}} &= \sum_i \sum_j (\bar{Y}_{i\cdot} - \bar{Y} + y_{ij} - \bar{Y}_{i\cdot})^2 \\ &= \underbrace{\sum_i n_i (\bar{Y}_{i\cdot} - \bar{Y})^2}_{\text{SSB}} + \underbrace{\sum_i \sum_j (y_{ij} - \bar{Y}_{i\cdot})^2}_{\text{SSR}} \end{aligned}$$

#### 7.1.6. Hipótesis nula

En un test ANOVA de un solo factor nuestra hipótesis nula es la siguiente:

$$H_0 : \alpha_1 = \alpha_2 = \dots = \alpha_a = 0 \quad \text{El efecto de cada grupo es equivalente a 0}$$

Equivalentemente:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_a = \mu$$

En este punto es evidente, pero aclaramos:

$$H_1 : \exists i : \alpha_i \neq 0$$

$$\begin{aligned} SSR &= \sum_i \sum_j (y_{ij} - \bar{Y}_{i.})^2 = \sum_i (n_i - 1) \hat{S}_i^2 \\ E(SSR) &= \sum_i (n_i - 1) \sigma^2 = (N - a) \sigma^2 \end{aligned}$$
$$E\left(\frac{SSR}{N - a}\right) = \sigma^2$$

Asumiendo además la **independencia de los residuos** tenemos que:

$$\frac{SSR}{\sigma^2} \sim \chi_{N-a}^2$$

$$SSB = \sum_i n_i (\bar{Y}_{i.} - \bar{Y})^2$$
$$E\left(\frac{SSB}{a-1}\right) = \frac{\sum_i n_i \alpha_i^2}{a-1} + \sigma^2$$

**Bajo  $H_0$ ,  $\frac{SSB}{a-1}$  es un estimador insesgado de  $\sigma^2$  y además:**

$$\frac{SSB}{\sigma^2} \sim \chi_{a-1}^2$$

### 7.1.9. Test para la hipótesis nula

$$\frac{\frac{\frac{SSB}{\sigma^2}}{a-1}}{\frac{\frac{SSR}{\sigma^2}}{N-a}} = \frac{\frac{SSB}{a-1}}{\frac{SSR}{N-a}} \sim F_{a-1, N-a}$$

Manuel Gijón Agudo

INCLUIR QQUÍ LA TABLA ANOVA MUAHAHAHHAHHAHAH

Rechazamos la hipótesis nula si  $F \geq F_{a-1, N-a, \alpha}$ .

## 7.2. Suposiciones sobre el modelo

Asumimos lo siguiente para los residuos:

- Normalmente distribuidos.
- Homogeneidad de varianzas.
- Independientes uno a uno.

Sobre el hecho de que estén normalmente distribuidos:

- Asumimos que los términos de error dentro de cada grupo provienen de poblaciones normalmente distribuidas ( $\epsilon_{ij} \sim N(0, \sigma_\epsilon)$ ).
- Si los tamaños muestrales y las varianzas son similares el test ANOVA es muy robusto respecto a esta suposición.
- Debemos comprobar la presencia de outliers, simetrías y bimodalidad.
- Podemos comprobar la normalidad de varias formas:
  - *Boxplots* de las observaciones de los residuos.
  - *Probability plots* de los residuos.
  - Test de normalidad.
    - Test de Wilks Shapiro.
    - Test de bondad de ajuste.

Consideraciones sobre la homeostadidad:

- Una hipótesis muy importante es asumir que las varianzas de los términos de error (y las observaciones en las poblaciones consideradas) son aproximadamente iguales en cada grupo.
- La anterior es más importante que la normalidad: si las varianzas no son similares el resultado del test F ANOVA se verá gravemente afectado.
- Un diseño balanceado ayuda a mitigar los efectos de la heteroestadidad.
- Si contamos con tamaños muestrales similares y el ratio entre la varianza mayor y la menor no excede 3 : 1, ANOVA es razonablemente robusto en este sentido.
- Comprobando la homeodasticidad:
  - *Boxplots* de los residuos deberían tener una dispersión similar.
  - Existen tests para comprobar, como  $H_0$ , que las varianzas entre las poblaciones son las mismas entre los grupos.
    - Test de Bartlett.
    - Test de Hartley.
    - Test de Cochran.

- Test de Levene.

Consideraciones sobre la independencia:

- Los términos de error y las observaciones deben de ser independientes.
  - Correlación positiva entre las réplicas dentro de los grupos deviene en una subestimación de la varianza real e incrementa el ratio de Errores de Tipo I.
  - Correlación negativa entre las réplicas dentro de los grupos implica una sobreestimación de la varianza real e incrementa el ratio de Errores de Tipo II.
- Esta hipótesis debe ser alcanzada durante las fases de diseño del experimento y recolección de datos (gran importancia de las técnicas de muestreo empleadas) y no puede ser enmendada después.

### 7.2.1. *Multiple testing*

Rechazar la hipótesis nula indica que al menos una de las medias poblacionales difiere de las otros, lo **no nos indica** cuál es la diferente.

- *Post-hoc unplanned pairwise comparisons*: se trata de comparar sistemáticamente todas las parejas entre sí.
- *Planned comparisons*: planeamos, normalmente durante el diseño del experimento, que poblaciones comparar entre sí.

*unplanned pairwise comparisons*:

- Existen una gran variedad de procedimientos para controlar el ratio de Errores del Tipo I, de este modo minimizamos estos errores.
- Estos procedimientos reducen la importancia de las comparaciones por parejas (incrementando los Errores de Tipo II), lo que está directamente relacionado con el número de grupos a comparar.

página 33 **CONTINUAR DESDE AQUÍ!!!!**

### 7.2.2. ANOVA de un factor aleatorio

$$\mu + \alpha_i = \mu_i$$

Reagrupando parámetros muhahahhhahhha

Notas sobre la probabilidad de equivocarse o acertar en comparaciones 2 a 2

1 - 0.95\*0.95 más o menos 0.1 (probabilidad de equivocarse en al menos 1 de ellos)

Si F > 1 podemos rechazar la hipótesis (MIRAR TODA ESTA MIERDA BIEN FUERTE)

alphas = media de cada tratamiento - media global

$E(SSR / N - a) = \sigma^2$  siempre se cumple muhehehehehe (REPSAR EST AMIERDA GORDA)

BLA BLA BLA BLA BLA BLA BLA BLA BLA BLA BLA BLA BLA BLA BLA BLA

La normalidad la comprobamos con los residuos, si usamos la variable original (la de densidad conjunta) podemos detectar no normalidad cuando la hay por que las mus sean distintas.

SI P ¡ALPHA RECHAZAMOS LA HIPÓTESIS NULA

Multiple testing = comparaciones múltiples muhahahahahahahahahahahahahahahahaha

CASO RANDOM Observemos que lo que comparamos es si los hospitales añaden variabilidad o no

La table y lo demás no varían

Luego deberemos **estimar las componentes de la varianza**

intraclass correlation = correlación intraclásica

## 7.3. Multifactor

### 7.3.1. Interpretando interacciones

Si se cruzan las líneas la combinación es significativa pero no hay interacción Insertar muchos gráficos cuquies aquí, muhahahahahahah

## 8. EJERCICIOS

### 8.1. Tema 1

#### 8.1.1. Métodos de muestreo

#### 8.1.2. Distribuciones de muestreo

## 8.2. Tema 2

### 8.2.1. Definiciones

### 8.2.2. Propiedades de los estimadores

Demostrar que la media aritmética es un estimador consistente para el parámetro  $\mu$  en una distribución  $N(\mu, \sigma)$ . Nota: usar la desigualdad de Chevychev:  $P(|X - E(X)| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}$

### 8.2.3. Métodos para la obtención de estimadores

Mostrar que el estadístico  $T = \sum_{i=0}^n x_i$  es suficiente para el parámetro  $p$  perteneciente a una muestra  $x_1, \dots, x_n$  que sigue una distribución  $B(1, p)$ .

AQUÍ IRÁ SU SOLUCIÓN MUHHAHHHHHAHHA

Dada una muestra aleatoria simple de una distribución  $N(\mu, 2)$ , verificar que la media muestral es un estimador suficiente para el parámetro  $\mu$ .

AQUÍ IRÁ SU SOLUCIÓN MUHHAHHHHHAHHA

Encontrar un estadístico suficiente por el método de la máxima verosimilitud para  $\theta$  para la distribución con la siguiente función de densidad bajo las condiciones  $\theta > 0$  y  $0 < x < 1$ :

$$f_{\theta}(x) = \theta x^{\theta-1}$$

Primero calculamos la función de densidad conjunta (**función de verosimilitud**) que, asumiendo independencia, es el producto de las funciones de densidad para cada  $x_i$ .

$$\begin{aligned} l(\theta; x_1, \dots, x_n) &= \prod_{i=1}^n f_{\theta}(x_i) \\ &= \prod_{i=1}^n \theta x_i^{\theta-1} \\ &= \theta^n \prod_{i=1}^n x_i^{\theta-1} \end{aligned} \tag{1}$$

Calculamos la el logaritmo de la función de verosimilitud para hacernos más sencillo calcular el **estimador de máxima verosimilitud (MLE)**  $\hat{\theta}$ :

$$\begin{aligned} L(\theta; x_1, \dots, x_n) &= \ln(l(\theta; x_1, \dots, x_n)) \\ &= \ln \left( \theta^n \prod_{i=1}^n x_i^{\theta-1} \right) \\ &= n \ln(\theta) + (\theta - 1) \sum_{i=1}^n \ln(x_i) \end{aligned} \tag{2}$$

Hallamos el mínimo de la función para encontrar el MLE y comprobamos que es mínimo (pasos obviados aquí).

$$L_{\theta}(\theta; x_1, \dots, x_n) = \frac{d}{d\theta} L(\theta; x_1, \dots, x_n) = \frac{n}{\theta} + \sum_{i=1}^n \ln x_i$$

$$L_{\theta}(\theta; x_1, \dots, x_n) = \frac{d}{d\theta} L(\theta; x_1, \dots, x_n) = 0$$

$$\Rightarrow \hat{\theta} = \frac{-n}{\sum_{i=1}^n \ln x_i} \quad (3)$$

Por el Teorema de Fisher–Neyman sabemos que nuestro estimador será suficiente sí y solo sí:

$$f_{\theta}(x) = h(x)g_{\theta}(T(x)) = h(x_1, \dots, x_n)g(T, \theta) = f(x_1, \dots, x_n; \theta)$$

Donde  $T$  es el estimador. Observemos que aquí tenemos como estimador (3) y todo se reduce por el teorema a conseguir escribir la función de densidad como una combinación de otras dos, una que solo dependa de la muestra y otra que dependa de la muestra y del parámetro  $\theta$ .

Sea  $x_1, \dots, x_n$  una muestra de una distribución normal  $N(\mu, \sigma)$ . Encontrar el método de los momentos para  $\mu$  y para  $\sigma$ .

[solución](#)

Encontrar el estimador por momentos del parámetro  $b$  de una distribución uniforme  $U(0, b)$ .

[solución](#)

Encontrar el estimador por el método de los momentos en los siguientes casos:

- Parámetro  $p$  en una distribución de Bernulli  $B(1, p)$ .
- Parámetro  $\alpha$  en una distribución Exponencial  $Exp(\alpha)$ .
- Parámetros  $\mu$  y  $\sigma$  en una Distribución Normal  $N(\mu, \sigma)$ .
- Parámetro  $b$  en una Distribución Uniforme  $U(0, b)$ .

- Parámetro  $p$  en una distribución de Bernulli  $B(1, p)$ .

[solución](#)

- Parámetro  $\alpha$  en una distribución Exponencial  $Exp(\alpha)$ .

[solución](#)

- Parámetros  $\mu$  y  $\sigma$  en una Distribución Normal  $N(\mu, \sigma)$ .

Sabemos que  $\mu = E(X)$  y que  $Var(X) = \sigma^2$  por la definición de distribución normal. Pero por definición de varianza también sabemos que  $Var(X) = E(X^2) - E(X)^2 = m_2 - m_1^2$ .

$$\Rightarrow \hat{\mu} = \bar{X}_n$$

$$\Rightarrow \hat{\sigma}^2 = \frac{\sum_{i=1}^n X_i^2}{n} - (\bar{X}_n)^2 = S^2$$



- Parámetro  $b$  en una Distribución Uniforme  $U(0, b)$ .

Sabemos por la definición de la distribución normal que  $E(X) = \frac{b}{2} \rightarrow b = 2E(X) = 2m_1$ , entonces:

$$\Rightarrow \hat{b} = 2\bar{X}_n$$

Encontrar el estimador por el método de los momentos en los siguientes casos:

- Parámetro  $p$  en una distribución de Bernulli  $B(1, p)$ .
- Parámetro  $\alpha$  en una distribución Exponencial  $Exp(\alpha)$ .
- Parámetros  $\mu$  y  $\sigma$  en una Distribución Normal  $N(\mu, \sigma)$ .
- Parámetro  $b$  en una Distribución Uniforme  $U(0, b)$ .

- Parámetro  $p$  en una distribución de Bernulli  $B(1, p)$ .

MLE para el parámetro  $p$  en una distribución de Bernulli  $X \sim B(1, p)$ .

Sabemos que su función de densidad, para  $x \in \{0, 1\}$  y  $0 \leq p \leq 1$  es:

$$f(x) = p^x (1 - p)^{1-x}$$

Tenemos una muestra de tamaño  $n$ :  $x_1, \dots, x_n$ .

Calculamos la función de verosimilitud:

$$l(p; x_1, \dots, x_n) = \prod_{i=1}^n p^{x_i} (1 - p)^{1-x_i}$$

Tomamos logaritmos:

Ahora buscaremos el máximo de la función  $L$  de la manera habitual, derivamos para hallar un candidato a máximo, que será nuestro estimador  $\hat{p}$

$$\begin{aligned} \frac{dL}{dp} &= \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1 - p} = 0 \\ \rightarrow \sum x_i - p \sum x_i - np + p \sum x_i &\Rightarrow p^* = \frac{\sum x_i}{n} \end{aligned}$$

Comprobamos ahora que se trata de un mínimo:

$$\frac{d^2L}{dp^2} = \frac{-\sum x_i}{p^2} - \frac{(n - \sum x_i)}{(1 - p)^2} < 0$$

Podemos concluir pues que  $\hat{p} = p^*$

- Parámetro  $\alpha$  en una distribución Exponencial  $Exp(\alpha)$ .

Sabemos que su función de densidad es  $f(x) = \frac{1}{\alpha} e^{-\frac{x}{\alpha}}$

$$l(\alpha; x_1, \dots, x_n) = \frac{1}{\alpha^n} e^{-\frac{\sum_{i=1}^n x_i}{\alpha}}$$

$$L(\alpha; x_1, \dots, x_n) = \ln(l)(\alpha; x_1, \dots, x_n) = -n \ln(\alpha) - \frac{\sum_{i=1}^n x_i}{\alpha}$$

$$\begin{aligned}\frac{\partial L}{\partial \alpha} &= \frac{-n}{\alpha} + \frac{\sum_{i=1}^n x_i}{\alpha^2} = 0 \\ -n\alpha + \sum x_i &= 0 \Rightarrow \hat{\alpha} = \frac{\sum x_i}{n} = \bar{x}_n \\ \frac{\partial^2 L}{\partial \alpha^2} &= \frac{n}{\alpha^2} - \frac{2\alpha \sum x_i}{\alpha^4} = \frac{n}{\alpha^2} - \frac{2 \sum x_i}{\alpha^3} \stackrel{?}{<} 0\end{aligned}$$

Teniendo en cuenta el hecho de que  $x > 0$  nos fijamos en el numerador de la expresión anterior para poder llegar al objetivo.

$$n\alpha - 2 \sum x_i \Rightarrow n\bar{x}_n - 2nx = \frac{-n\bar{x}_n}{\bar{x}_n^3} < 0$$

- Parámetros  $\mu$  y  $\sigma$  en una Distribución Normal  $N(\mu, \sigma)$ .

Sabemos que si  $X \sim N(\mu, \sigma)$  entonces:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{\frac{-(x-\mu)^2}{2\sigma^2}}$$

$$l(\mu, \sigma; x_1, \dots, x_n) = \left( \frac{1}{\sigma\sqrt{2\pi}} \right)^n e^{\frac{-\sum (x_i - \mu)^2}{2\sigma^2}}$$

$$L(\mu, \sigma; x_1, \dots, x_n) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \sum \frac{(x_i - \mu)^2}{2\sigma^2}$$

$$\begin{cases} \frac{\partial L}{\partial \mu} = -\frac{2 \sum (x_i - \mu)}{2\sigma^2} = -\sum \frac{x_i - \mu}{\sigma^2} = 0 \\ \frac{\partial L}{\partial \sigma} = -\frac{n}{2\sigma^2} + \sum \frac{(x_i - \mu)^2}{2(\sigma^2)^2} = 0 \end{cases}$$

- De la primera de las ecuaciones obtenemos:

$$\sum (x_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{x}_n$$

- De la segunda (quedando cálculos pendientes):

$$\begin{aligned}-n\sigma^2 + \sum (x_i - \mu)^2 &= 0 \\ -n\sigma^2 + \sum (x_i - \bar{x}_n)^2 &= 0 \\ \Rightarrow \hat{\sigma}^2 &= \sum \frac{(x_i - \bar{x}_n)^2}{n} = S^2\end{aligned}$$

- Parámetro  $b$  en una Distribución Uniforme  $U(0, b)$ .

Como sabemos la función de densidad de una variable aleatoria  $X \sim U(0, b)$  es:

$$f(x) = \frac{1}{b} \quad 0 < x < b$$

$$x_1, x_2, \dots, x_n \longrightarrow l(x_1, \dots, x_n) = \prod_{i=1}^n f(x_i) = \frac{1}{b^n}$$

$$\ln(l(x_1, \dots, x_n)) = -n \ln(b)$$

$$\frac{\partial L}{\partial b} = \frac{-n}{b} \neq 0 \text{ para cualquier valor de } b$$

$\Rightarrow$  La ecuación de verosimilitud NO TIENE SOLUCIÓN!!

En este caso nuestro estimador será el siguiente (aunque no llegaremos a él por este método):

$$\hat{b} = \max \{x_1, x_2, \dots, x_n\}$$

Consideremos el siguiente modelo de regresión, siendo  $e \sim N(0, \sigma)$ :

$$y_i = \alpha + \beta x_i + e$$

Probar que los estimadores por máxima verosimilitud y por el método de los momentos para los parámetros  $\alpha$  y  $\beta$  resultan el mismo.

**solución**

Sea  $X$  una variable aleatoria que sigue una distribución exponencial de parámetro  $\alpha$ .

$$f(x) = \frac{1}{\alpha} e^{-\frac{x}{\alpha}}$$

Para  $x \geq 0$ .

- Hallar el estimador máximo verosímil de  $\alpha$  para una muestra aleatoria de tamaño  $n$ .
- Referido al estimador anterior:
  - ¿Es un estimador insesgado?
  - Hallar el error cuadrático medio del estimador.
  - ¿Cuál es la eficiencia absoluta del estimador?
- Hay tres tipos de babosas: verdes, púrpuras y rayadas. El tiempo de vida de las babosas verdes sigue una distribución exponencial de parámetro  $\alpha$ . El tiempo de vida de las babosas púrpura sigue una distribución exponencial de parámetro  $4\alpha$ . El tiempo de vida de las babosas rayadas sigue una distribución exponencial de parámetro  $16\alpha$ . Hemos observado la siguiente muestra:
  - 1 babosa verde con un tiempo de vida de 39.
  - 2 babosas púrpura con tiempos de vida de 45 y 165.
  - 1 babosa rayada con un tiempo de vida de 900.

Utilizar el método de la máxima verosimilitud para hallar  $\alpha$ .

■ **solución**

■ **solución**

- **solución**
- **solución**
- **solución**

- [solución](#)
- [solución](#)
- [solución](#)

Sean  $X_1, \dots, X_n$  variables aleatorias independientes e idénticamente distribuidas con la siguiente función de densidad para cada  $X_i$  (con  $x > 0$ ):

$$f(x; \theta) = \frac{x^2}{2\theta^3} e^{-\frac{x}{\theta}}$$

Como dato sabemos que  $E(X) = 3\theta$  y que  $Var(X) = 3\theta^2$ .

- Hallar el estimador por el método de los momentos de  $\theta$ .
- Calcular la función de verosimilitud para una muestra aleatoria de tamaño  $n$ .
- Hallar el estimador máximo verosímil de  $\theta$ .
- Demostrar que ambos estimadores son insesgados.
- Demostrar que  $\sum_{i=1}^n X_i$  es un estimador suficiente para el parámetro  $\theta$ .
- Halla la cota de Cramer-Rao para la varianza de un estimador insesgado de  $\theta$ .
- ¿Cuál es el valor de la información de Fisher en una observación individual de esta densidad?
- ¿Es el estimador de máxima verosimilitud el estimador insesgado de la varianza mínima de  $\theta$ ?
- Hallar el estadístico del test de la razón de verosimilitud para contrastar la hipótesis  $H_0 : \theta = \theta_0$  contra la alternativa  $H_1 : \theta \neq \theta_0$ .
- Supongamos que tenemos una muestra aleatoria de tamaño  $n = 27$  produce  $\sum_{i=1}^{27} x_i = 108$ . Utilizando el contraste obtenido antes, ¿podemos rechazar la hipótesis  $H_0 : \theta = 1$  frente a la alternativa  $H_1 : \theta \neq 1$  con un nivel de significación de  $\alpha = 0,1$  ?
- BONUS: comprobar los valores de la varianza y de la esperanza.

- [solución](#)
- [solución](#)
- [solución](#)
- [solución](#)
- [solución](#)
- [solución](#)
- [solución](#)
- [solución](#)
- [solución](#)
- [solución](#)
- [solución](#)

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una distribución  $X \sim N(\mu, \sigma)$ . Dados los siguientes estimadores ¿cuál es preferible desde el punto de vista de MLE?

$$T(X) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$U(X) = \frac{1}{n+1} \sum_{i=1}^n (X_i - \bar{X})^2$$

[solución](#)

Tenemos una muestra aleatoria de la variable definida por la siguiente función de densidad (para  $0 < x < \beta$ ):

$$f(x, \beta) = \frac{2}{\beta^2}(\beta - x)$$

Encontrar los estimadores por el método de máxima verosimilitud y por momentos para  $\beta$ . Encontrar la desviación de cada uno de los estimadores y también la eficiencia relativa del procedente de la máxima verosimilitud respecto al hallado por momentos.

#### 8.2.4. Métodos de remuestreo

### **8.3. Tema 3**

#### **8.3.1. Cantidades pivotaes**

#### **8.3.2. Intervalos usuales**

#### **8.3.3. Intervalos de confianza asintóticos**

#### **8.3.4. Evaluación de intervalos de confianza**

#### **8.3.5. Determinación del tamaño muestral**

## 8.4. Tema 4

### 8.4.1. Test de máxima verosimilitud

Sea  $x_1, \dots, x_n$  una muestra aleatoria de valores independientes de la siguiente variable  $X \sim N(\mu, \sigma)$ .

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu \neq \mu_0$$

Observemos que en nuestros espacios serán  $\Theta := \{(\mu, \sigma) : \mu \neq \mu_0\}$  y  $\Theta_0 := \{(\mu_0, \sigma)\}$ .

$$l(\mu, \sigma; x_1, \dots, x_n) = \left( \frac{1}{\sigma\sqrt{2\pi}} \right)^n e^{-\frac{\sum (x_i - \mu)^2}{2\sigma^2}}$$

■ En  $\Theta$ :

$$\begin{aligned}\hat{\mu} &= \bar{x} \\ \hat{\sigma}^2 &= S^2 = \frac{\sum (x_i - \bar{x})^2}{n}\end{aligned}$$

■ En  $\Theta_0$ :

$$\begin{aligned}l &= \left( \frac{1}{\sigma\sqrt{2\pi}} \right)^n e^{-\frac{\sum (x_i - \mu_0)^2}{2\sigma^2}} \\ L &= -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{\sum (x_i - \mu_0)^2}{2\sigma^2} \\ L_\theta &= -\frac{1}{2\sigma^2} + \frac{\sum (x_i - \mu_0)^2}{2(\sigma^2)^2} = 0 \\ &\Rightarrow -n\sigma^2 + \sum_{i=1}^n (x_i - \mu_0)^2 = 0 \\ &\Rightarrow \hat{\sigma}^2 = \frac{\sum (x_i - \mu_0)^2}{n}\end{aligned}$$

Sabemos por la teoría que:

$$\Lambda = \frac{l(\hat{\Theta}_0)}{l(\hat{\Theta})}$$

Nos centraremos en el numerados, ya que el denominador es similar pero utilizando  $\bar{x}$ .

Llegado cierto punto, utilizaremos también el hecho de que  $\frac{\bar{x} - \mu_0}{S/\sqrt{n-1}} \sim T_{n-1}$ .

$$l(\hat{\Theta}_0) =$$

Test de máxima verosimilitud para la varianza de distribuciones normales (  $X \sim M(\mu_i, \sigma_i)$   $i = 1, 2, \dots, k$  ) con el siguiente test:

$$H_0 : \sigma_1 = \sigma_2 = \cdots = \sigma_k = \sigma$$

$$H_1 : \exists i, j : \sigma_i \neq \sigma_j$$

$$l = \prod_{i=1}^k \left( \frac{1}{\sigma_i \sqrt{2\pi}} \right)^{n_i} e^{-\frac{\sum_{j=1}^{n_i} (x_{ij} - \mu_i)^2}{2\sigma_i^2}}$$

Ahora tomaremos logaritmos y derivaremos:

■ En  $\Theta$ :

$$\hat{\mu}_i = \bar{x}_i$$

$$\hat{\sigma}_i = S_i^2 = \frac{\sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2}{n_i}$$

■ En  $\Theta_0$ :

$$n_1 + n_2 + \cdots + n_k = N$$

$$l = \left( \frac{1}{\sigma \sqrt{2\pi}} \right)^N e^{-\frac{\sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \mu_i)^2}{2\sigma^2}}$$

$$\hat{\mu}_i = \bar{x}_i$$

$$\begin{aligned} L &= -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma^2) - \sum_{i=1}^k \sum_{j=1}^{n_i} \frac{(x_{ij} - \bar{x}_i)^2}{2\sigma^2} \\ \frac{\partial L}{\partial \sigma^2} &= -\frac{N}{2\sigma^2} + \frac{\sum_i \sum_j (x_{ij} - \bar{x}_i)^2}{2(\sigma^2)^2} = 0 \\ \Rightarrow -N\sigma^2 + \sum_i \sum_j (x_{ij} - \bar{x}_i)^2 &= 0 \\ \Rightarrow \hat{\sigma}^2 &= \frac{\sum_i \sum_j (x_{ij} - \bar{x}_i)^2}{N} \end{aligned}$$

$$\hat{\sigma}^2 = \frac{\sum_i n_i S_i^2}{N}$$

$$\begin{aligned} \Lambda &= \frac{l(\hat{\Theta}_0)}{l(\hat{\Theta})} = \dots \\ &= \frac{\prod_{i=1}^k (S_i^2)^{\frac{n_i}{2}}}{(S^2)^{\frac{N}{2}}} \end{aligned}$$

Ahora utilizaremos el Teorema de Wills:

$$U = -2 \ln \Lambda = -2 \left( \sum_{i=1}^k \frac{n_i}{2} \ln(S_i^2) - \frac{N}{2} \ln(S^2) \right)$$

$$\text{Bajo } H_0: U \sim \chi_{2k-(k+1)}^2 = \chi_{k-1}^2$$



(Tenemos  $2k$  parámetros en  $\Theta$  (su dimensión) y  $k + 1$  en  $\Theta_0$ )

En el siguiente ejemplo justificaremos el TEST ANOVA a partir de la Razón de Verosimilitud

Test de máxima verosimilitud para la media de distribuciones normales (  $X \sim M(\mu_i, \sigma_i)$   $i = 1, 2, \dots, k$  ) con el siguiente test:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k = \mu$$

$$H_1 : \exists i, j : \mu_i \neq \mu_j$$

$$l = \left( \frac{1}{\sigma\sqrt{2\pi}} \right) e^{\frac{-\sum_i \sum_j x_{ij} (x_{ij} - \mu_i)^2}{2\sigma^2}}$$

■ En  $\Theta$ :

$$\hat{\mu}_i = \bar{x}_i$$

Ahora utilizaremos la terminología ANOVA (que veremos en próximos temas).

$$\hat{\sigma}^2 = \frac{\sum_i \sum_j (x_{ij} - \bar{x}_i)^2}{N} = \frac{SSW}{N}$$

■ En  $\Theta_0$ :

$$l = \left( \frac{1}{\sigma\sqrt{2\pi}} \right)^N e^{\frac{-\sum_i \sum_j (x_{ij} - \mu)^2}{2\sigma^2}}$$

Utilizaremos la siguiente igualdad aunque no la demostremos aquí:

$$SST = \underbrace{\sum_i n_i (\bar{x}_i - \bar{x})^2}_{SSB} + \underbrace{\sum_i \sum_j (x_{ij} - \bar{x}_i)^2}_{SSW}$$

$$\hat{\mu} = \frac{\sum_i \sum_j x_{ij}}{N} = \bar{x}$$

$$\begin{aligned} \hat{\sigma}^2 &= \frac{\sum_i \sum_j (x_{ij} - \bar{x})^2}{N} = \frac{SST}{N} \\ &= \frac{SSB + SSW}{N} \end{aligned}$$

$$\Rightarrow \Lambda = \frac{\left( \frac{SSW}{N} \right)^{N/2}}{\left( \frac{SSB + SSW}{N} \right)^{N/2}} = \left( \frac{SSW}{SSB + SSW} \right)^{\frac{N}{2}}$$

Rechazaremos la hipótesis si  $\Lambda < k_\alpha$ :

$$\begin{aligned} &\Rightarrow \frac{SSB + SSW}{SSW} > c' \\ &\Rightarrow \frac{SSB}{SSW} + 1 > c' \iff \frac{SSB}{SSW} > c'' \end{aligned}$$

Ya sabíamos lo que esto implica,  $\frac{nS^2}{\sigma^2} \sim \chi_{n-1}^2$

$$SSW = \sum n_i S_i$$

Las dos siguientes variables aleatorias serán independientes:

- $\frac{SSW}{\sigma^2} = \frac{\sum_i n_i S_i^2}{\sigma^2} \sim \chi_{N-k}^2$
- $\frac{n_i S_i^2}{\sigma^2} \sim \chi_{n_i-1}^2$

Análogamente es demostrable lo siguiente:

$$\begin{aligned} &\frac{SSB}{\sigma^2} \sim \chi_{k-1}^2 \\ &\Rightarrow \frac{\left(\frac{SSB}{\sigma^2}\right)/k - 1}{\left(\frac{SSW}{\sigma^2}\right)/N - k} = \frac{SSB/k - 1}{SSW/N - k} \sim \mathfrak{F}_{k-1, N-k} \end{aligned}$$

$$X \sim f(x; \theta)$$

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta = \theta_1$$

Observemos que el test nos indica lo siguiente:

$$\Theta = \{\theta_0, \theta_1\}$$

Así tenemos:

$$\Lambda = \frac{l(\widehat{\Theta}_0)}{l(\widehat{\Theta})} = \frac{l(\theta_0)}{\max\{l(\theta_0), l(\theta_1)\}} = \begin{cases} 1 & \text{si } l(\theta_0) > l(\theta_1) \\ \frac{l(\theta_0)}{l(\theta_1)} & \text{si } l(\theta_0) < l(\theta_1) \end{cases}$$

8.4.2. Test no paramétricos robustos

8.4.3. Test múltiple

8.4.4. Test clásicos no paramétricos

8.4.5. Test de Fisher

8.4.6. Determinación del tamaño muestral

## 8.5. Tema 5

### 8.5.1. Ajuste del modelo

### 8.5.2. Table ANOVA

### 8.5.3. Bondad del ajuste

### 8.5.4. Distribución de los coeficientes

### 8.5.5. Intervalos de confianza para los coeficientes

### 8.5.6. Predicción

### 8.5.7. Correlación, causalidad e interpretación

## **8.6. Tema 6**

**8.6.1. Estimación de parámetros (un factor)**

**8.6.2. Partición de la varianza (un factor)**

**8.6.3. Hipótesis nula y tests para la hipótesis nula**